

Report del Progetto Milan Housing

Mattia Faini

1 Pulizia e dei dati, imputazione dei valori mancanti e trasformazioni dei predittori

Nel `training` set e nel `test` set alcuni valori erano mancanti o inconsistenti, inoltre per alcuni predittori è stato ritenuto opportuno applicare una trasformazione. Ecco come è stato trattato ciascun campo del dataset:

- Per la variabile `bathrooms_number` i valori mancanti sono stati imputati tramite regressione logistica cumulata usando come predittore la variabile `square_meters`.
- La variabile `rooms_number` non presentava valori mancanti. Il valore 5+ è stato convertito in 6.
- Per la variabile `square_meters` sono stati individuati alcuni valori incompatibili con i rispettivi valori di `rooms_number`, perciò questi sono stati sostituiti con valori previsti tramite modello lineare usando la variabile `rooms_number` come predittore. Inoltre è stata creata la variabile `sqm_1` pari all'inverso dei metri quadri.
- Dalla variabile risposta `selling_price` è stata creata una nuova variabile, il logaritmo del prezzo al metro quadro `sqm_price` che verrà usata per stimare il modello finale e calcolare le predizioni.
- I valori mancanti per la variabile `year_of_construction` sono stati imputati usando la media degli altri valori. Inoltre è stata creata la dummy `new` che vale 1 se la casa è stata costruita dopo il 2010.
- I valori mancanti per la variabile `total_floors_in_building` sono stati imputati con un modello lineare usando come predittore `year_of_construction`.
- La variabile `car_parking` è stata separata nelle variabili `shared_parking` e `garage_box` che rappresentano rispettivamente i posti auto nei garage e negli spazi comuni.
- La variabile `availability` è stata trasformata in una dummy che vale 0 se la casa non è subito disponibile e 1 se lo è.
- La variabile `floor` è stata trasformata in una variabile numerica, i valori `ground`, `mezzanine` e `basement` sono stati posti a zero e sono state create delle dummy corrispondenti. Inoltre è stata creata la variabile `ratio`, il rapporto tra `floor` e `total_floors_in_building`.
- La variabile `energy_efficiency_class` è stata trasformata in valori numerici e i valori mancanti sono stati previsti tramite regressione logistica cumulata.

- Dalla variabile `other_features` sono state create delle dummy per ciascuna feature compresa una dummy NA che indica se per la casa non vengono riportate features.
- La variabile `lift` è stata trasformata in dummy che vale 0 se la casa ha l'ascensore e 1 se non ce l'ha. I valori mancanti sono stati previsti tramite regressione logistica. Inoltre è stata creata la variabile `floor_lift`, il prodotto di `floor` e `lift` in modo da selezionare le case senza ascensore ai piani alti.
- La variabile `condominium_fees` è stata convertita in numerica e divisa per `square_meters` e i valori mancanti sono stati imputati con la media.
- I valori mancanti per le variabili `heating centralized` e `conditions` sono stati imputati con la moda.
- I valori della variabile `zone` sono stati geolocalizzati usando l'API di Google Maps e importati nel software geografico QGIS e sono stati corretti gli errori di geolocalizzazione. Inoltre come mostrato in Figura 1 è stata impostata una legenda per mostrare quante osservazioni per ciascuna zona erano presenti nel `training set`. Le zone con meno di 3 osservazioni nel `training set` sono state aggregate a zone limitrofe.




Figura 1: Mappa di Milano con le zone presenti nei dataset e legenda che mostra il numero di osservazioni per ciascuna zona in training.

2 Il modello

Essendo la funzione di perdita da minimizzare una perdita assoluta (MAE), la scelta è stata quella di utilizzare un modello di regressione quantilica. Il problema della regressione quantilica è che non è facile implementare tecniche di riduzione della dimensionalità o shrinkage come lasso, group lasso, ridge e PCA. Tuttavia facendo tentativi con queste tecniche sul dataset non sono stati ottenuti risultati soddisfacenti, perciò nonostante la maggior complessità computazionale si è comunque preferita la regressione quantilica.

2.1 Tentativo di riduzione della dimensionalità delle zone

Si è tentato di aggregare le zone usando l'algoritmo k-means sulle coordinate e testando i risultati su un test set ottenuto da un subset di **training**, ottenuto per estrazione casuale ma avendo cura di dividere proporzionalmente le osservazioni di ciascuna zona nel training e nel test set. Si è stimata una serie regressioni utilizzando tutti i predittori e le zone aggregate in sempre meno gruppi in modo simile a una backward regression. Come si nota da Figura 2 l'errore cresce quasi monotonamente diminuendo il numero di zone. Perciò si decise di mantenere tutte le zone nei successivi passi.




Figura 2: Errore medio assoluto sul test set in funzione del numero di zone diverse incluse. Il numero di zone è stato ridotto aggregando le zone tramite kmeans sulla base delle coordinate geografiche. La linea verticale mostra il punto con il MAE più basso.

2.2 Scelta finale dei predittori

Per ridurre la dimensionalità si è tentato di usare una backward regression, escludendo ogni volta il predittore con il p-value più alto, tuttavia i risultati cambiavano molto a seconda dei training e test set scelti. Perciò sono stati selezionati 50 modelli diversi tramite backward regression e ciascuno è stato valutato su 50 training e test set diversi

(Figura 3). Il modello scelto, da usare per la predizione finale, è stato quello con il MAE più basso, la cui varianza è accettabile. Un difetto di questo metodo è che i dati usati per questa valutazione finale dei modelli sono già stati usati per selezionare i 50 modelli candidati. Inoltre la stima del MAE ottenuta per il modello è biased dal fatto che quella stessa stima è stata usata per scegliere il modello.




Figura 3: Distribuzione del numero di predittori, del MAE e della deviazione standard del MAE per 50 modelli ottenuti da backward regression da 50 test e training set e valutati su altri 50 test e training set. La linea verticale indica i valori per il modello finale selezionato. Le dummy per le zone conteggiate come un unico predittore, lo stesso vale per conditions.